АНСАМБЛИ В TRITON INFERENCE SERVER

AGENDA

01 **Пайплайн инференса**

02 Ансамблирование пайплайна

03 **Пример ансамбля**

Пайплайн инференса

Задача классификации текста

Входной текст → PreProcessing → Токенизация текста → Инференс модели → PostProcessing

Пайплайн инференса

Задача классификации текста

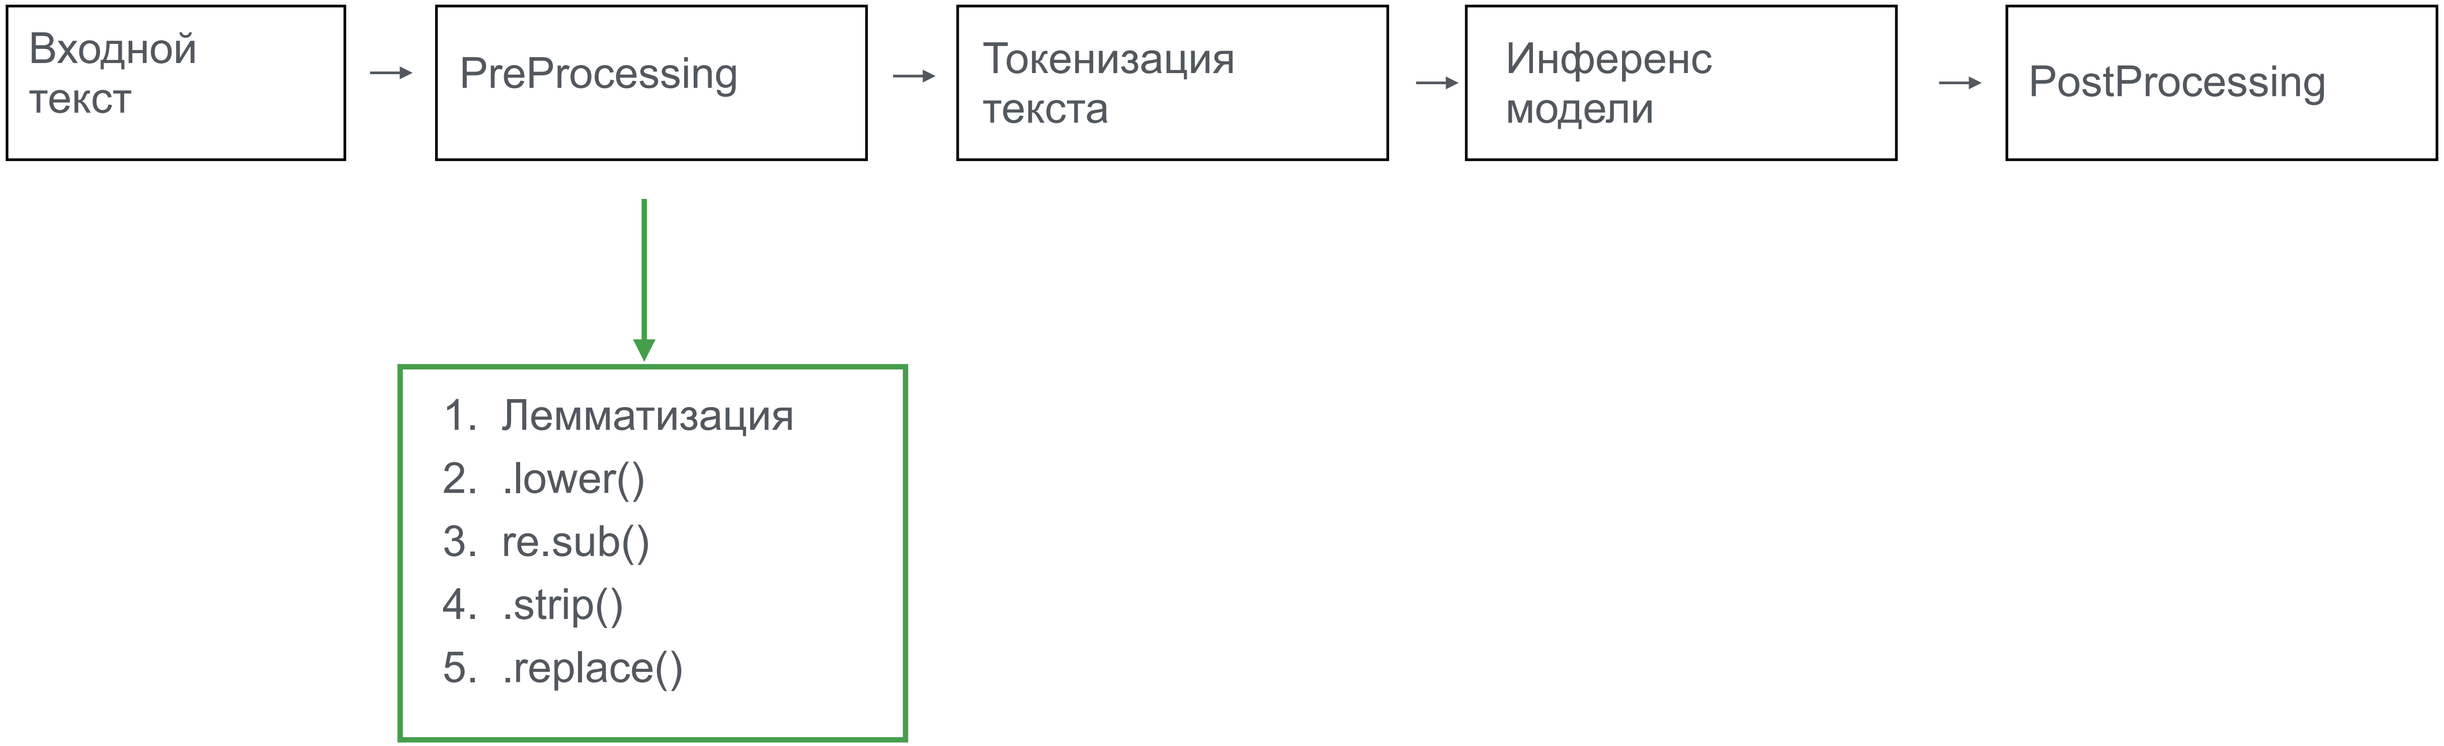

Пайплайн инференса

Задача классификации текста

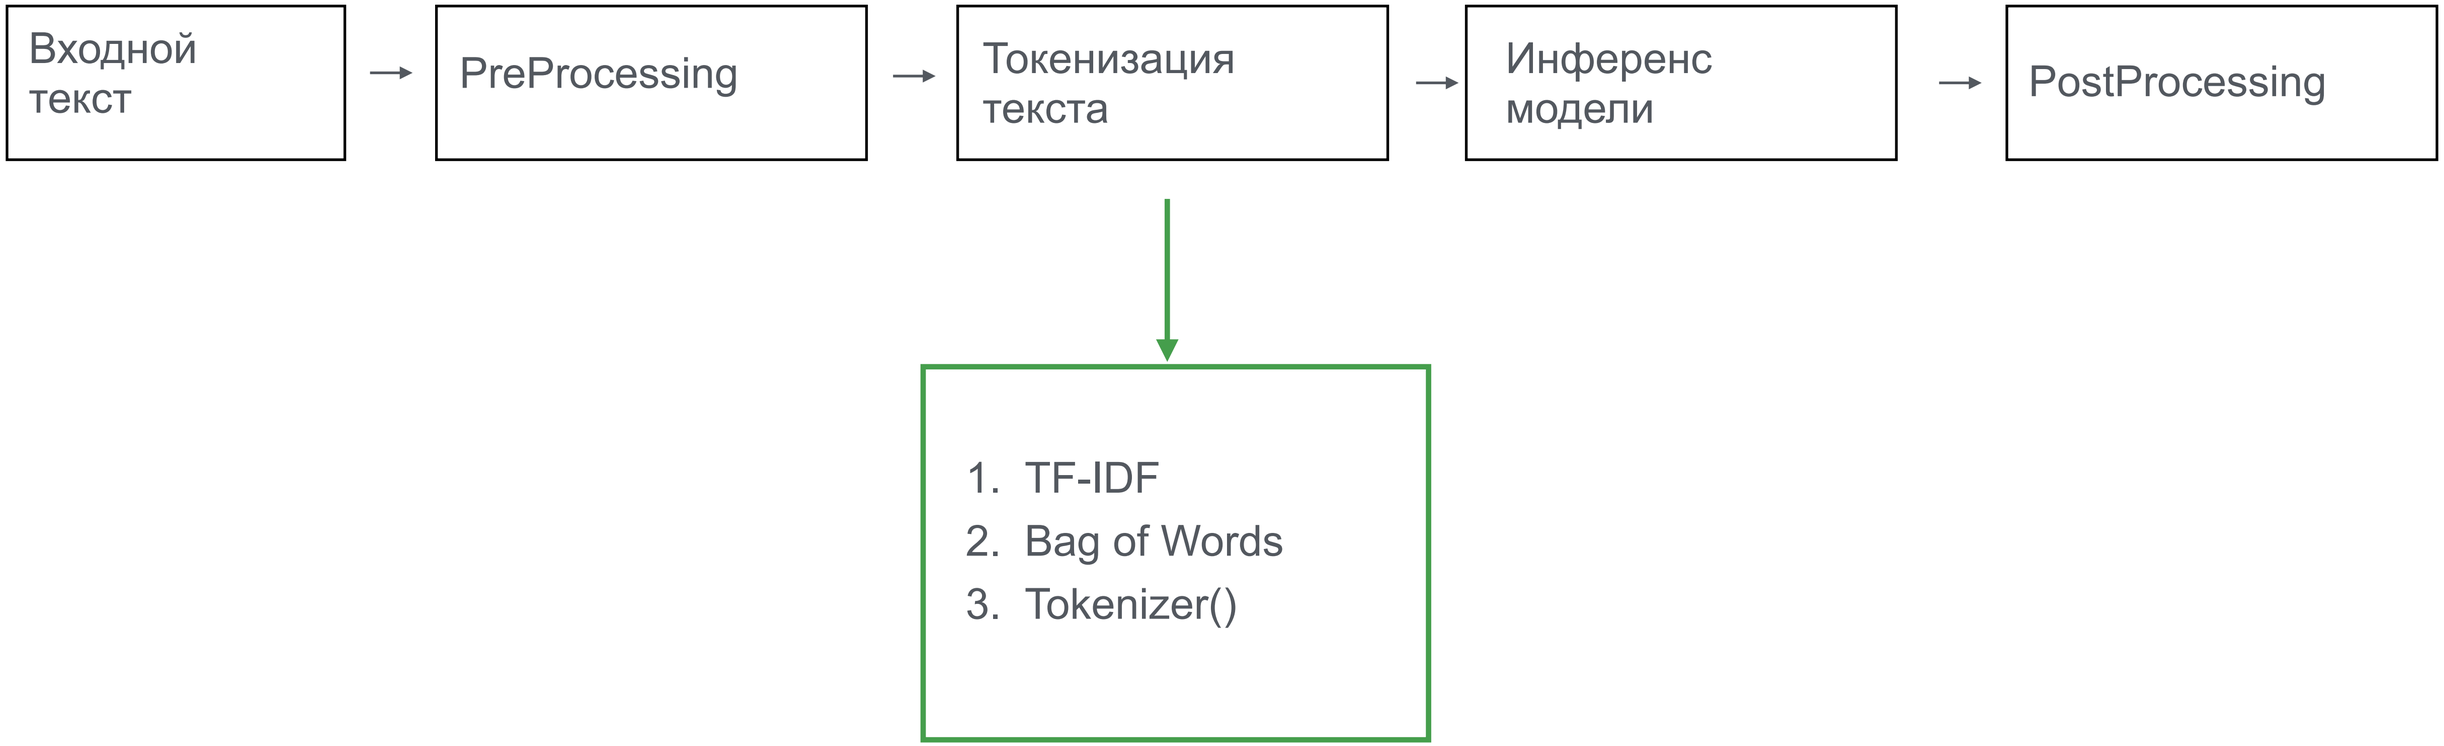

Пайплайн инференса

Задача классификации текста

Входной текст → PreProcessing → Токенизация текста → Инференс модели → PostProcessing

```
model.load_weight()
model.eval()
with torch.no_grad():
    model(data)
```

Пайплайн инференса

Задача классификации текста

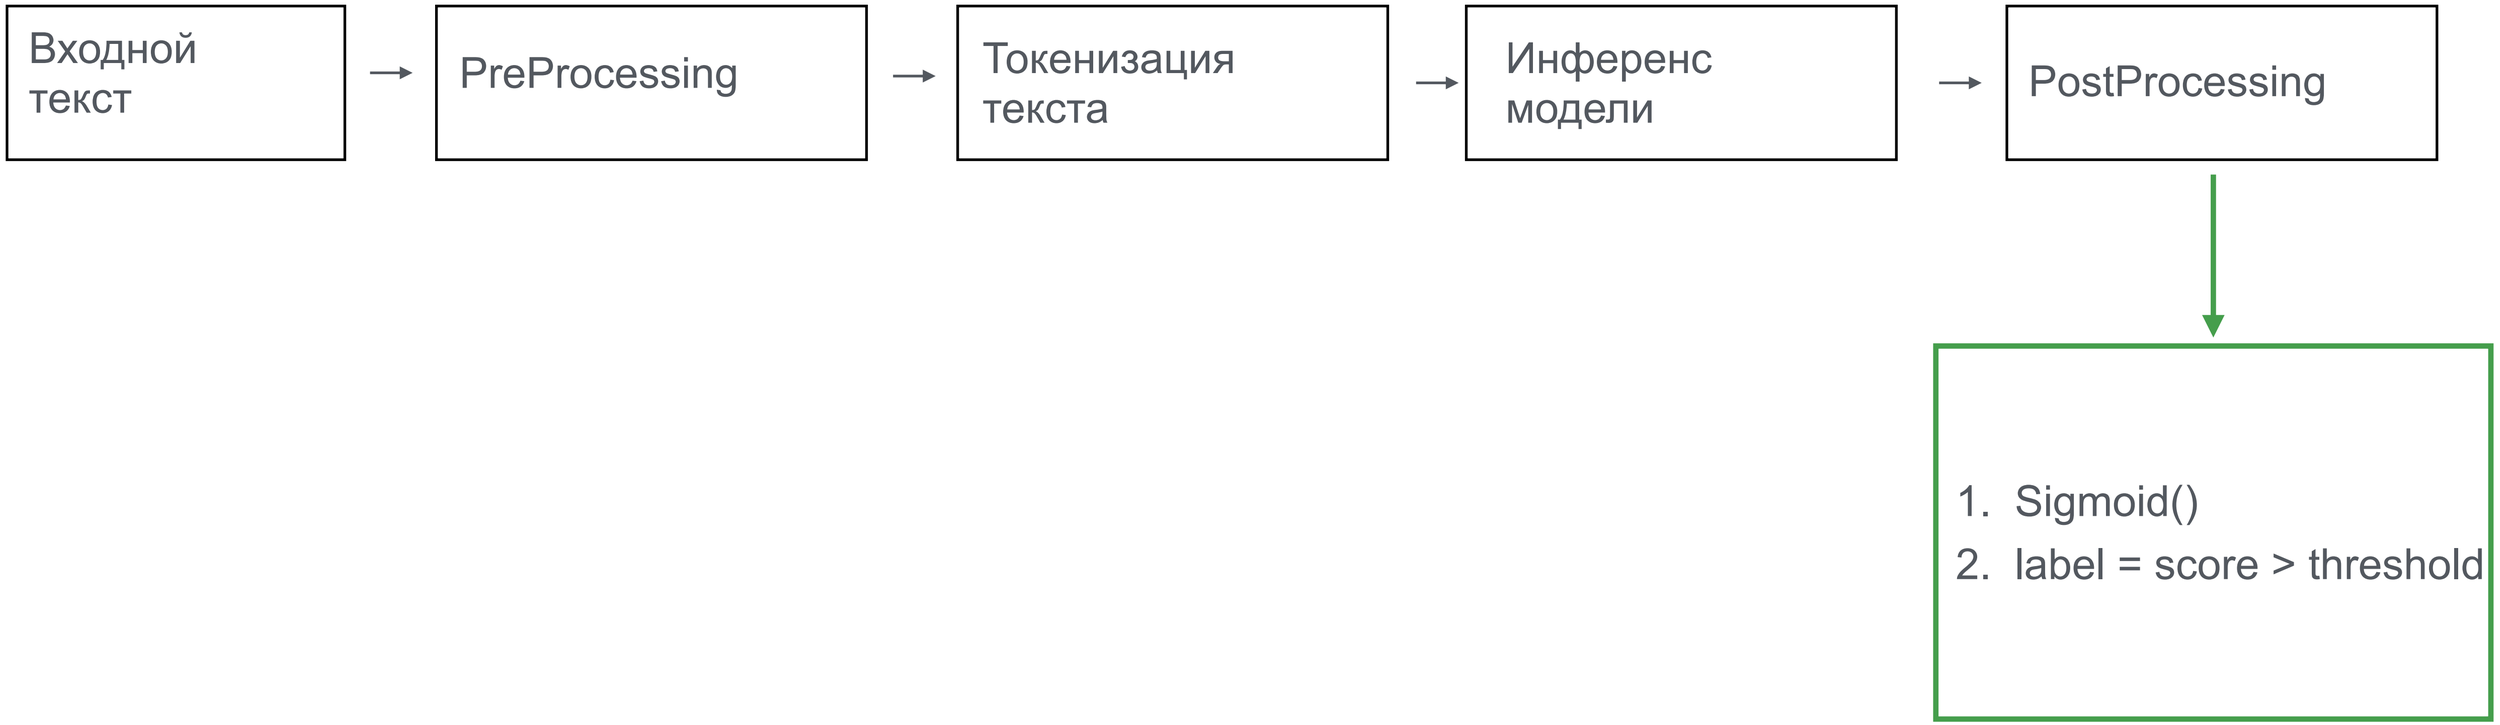

Пайплайн инференса

Задача классификации текста

```python
def preprocess(text):
    return text.lower()

def tokenize(text, tokenizer):
    return tokenizer(
        text,
        max_length=512,
        truncation=True,
        padding="max_length",
        return_tensors="pt"
        )

def infer_model(tokenized_text, model):
    with torch.no_grad():
        outputs = model(**tokenized).logits.detach().cpu()
    return outputs

def postprocess(logits, threshold):
    return logits.sigmoid() > threshold

def pipeline(text, model, tokenizer, threshold):
    preprocessed_text = preprocess(text)
    tokenized_text = tokenize(preprocessed_text, tokenizer)
    logits = infer_model(tokenized_text, model)
    labels = postprocess(logits, threshold)
    return labels
```

Пайплайн инференса

Задача классификации текста

```python
def preprocess(text):
    return text.lower()

def tokenize(text, tokenizer):
    return tokenizer(
        text,
        max_length=512,
        truncation=True,
        padding="max_length",
        return_tensors="pt"
        )

def infer_model(tokenized_text, model):
    with torch.no_grad():
        outputs = model(**tokenized).logits.detach().cpu()
    return outputs

def postprocess(logits, threshold):
    return logits.sigmoid() > threshold

def pipeline(text, model, tokenizer, threshold):
    preprocessed_text = preprocess(text)
    tokenized_text = tokenize(preprocessed_text, tokenizer)
    logits = infer_model(tokenized_text, model)
    labels = postprocess(logits, threshold)
    return labels
```

1. Как масштабировать?
    1. Токенизатор работает намного быстрее инференса модели

Пайплайн инференса

Задача классификации текста

```python
def preprocess(text):
    return text.lower()

def tokenize(text, tokenizer):
    return tokenizer(
        text,
        max_length=512,
        truncation=True,
        padding="max_length",
        return_tensors="pt"
        )

def infer_model(tokenized_text, model):
    with torch.no_grad():
        outputs = model(**tokenized).logits.detach().cpu()
    return outputs

def postprocess(logits, threshold):
    return logits.sigmoid() > threshold

def pipeline(text, model, tokenizer, threshold):
    preprocessed_text = preprocess(text)
    tokenized_text = tokenize(preprocessed_text, tokenizer)
    logits = infer_model(tokenized_text, model)
    labels = postprocess(logits, threshold)
    return labels
```

1. Как масштабировать?
    1. Токенизатор работает намного быстрее инференса модели
    2. Неочевидно, как использовать несколько GPU

Ансамблирование пайплайна

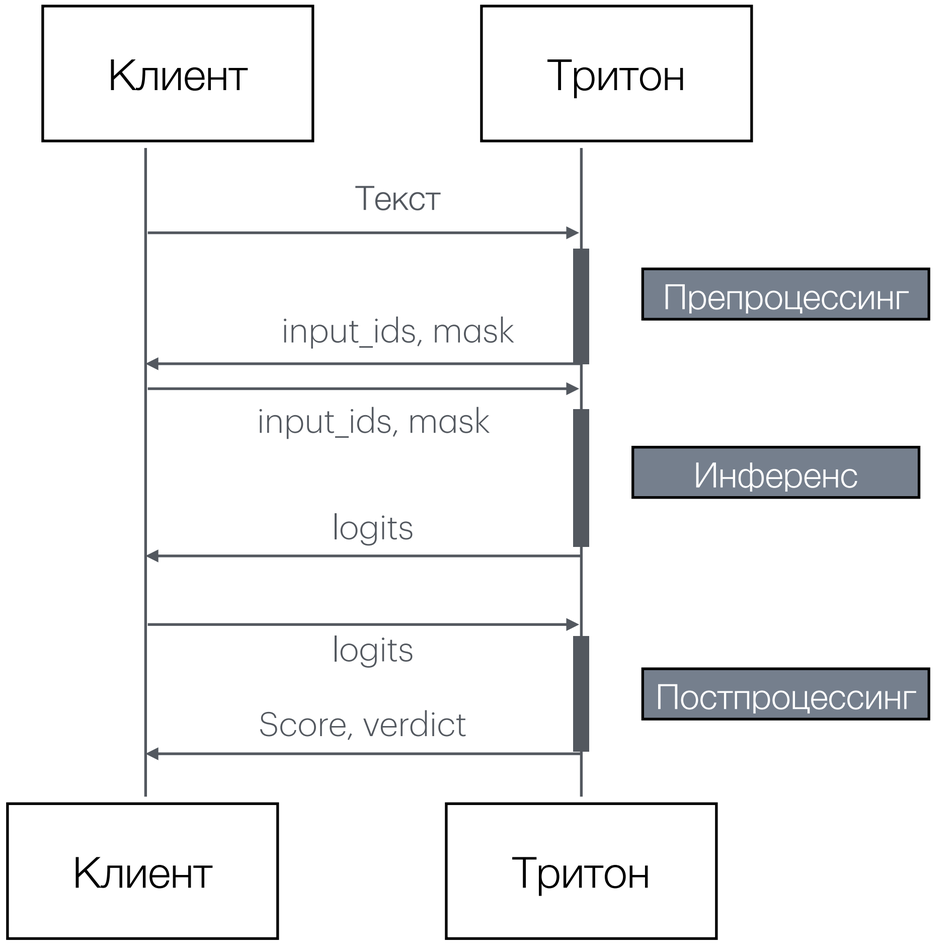

1. Итеративно вызываем каждую модель.
2. Нужно сохранять промежуточные результаты в памяти или на диске.

Ансамблирование пайплайна

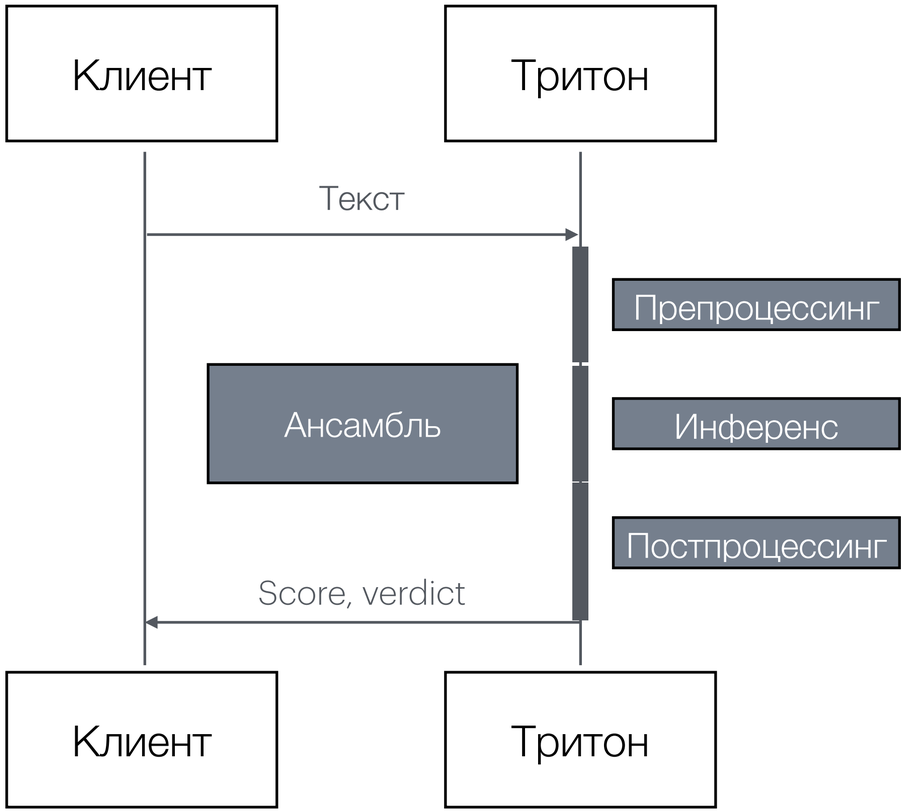

1. Делаем один вызов ансамбля.
2. Не нужно сохранять промежуточные результаты, сразу получаем желаемое.

Ансамблирование пайплайна

Задача классификации текста

Ансамбль — это система, построенная из одной и более моделей (пайплайн), представленная в виде **направленного графа** без циклов. Представлять решение в виде ансамбля следует, когда не удаётся всю логику собрать на одном бэкенде или появляются узкие места, избавиться от которых можно только с помощью увеличения числа экземпляров отдельных моделей.

Сам по себе ансамбль — это просто спецификация (конфигурационный файл), определяющая порядок передачи данных между моделями с **консистентными** входами и выходами.

Ансамблирование пайплайна

Задача классификации текста

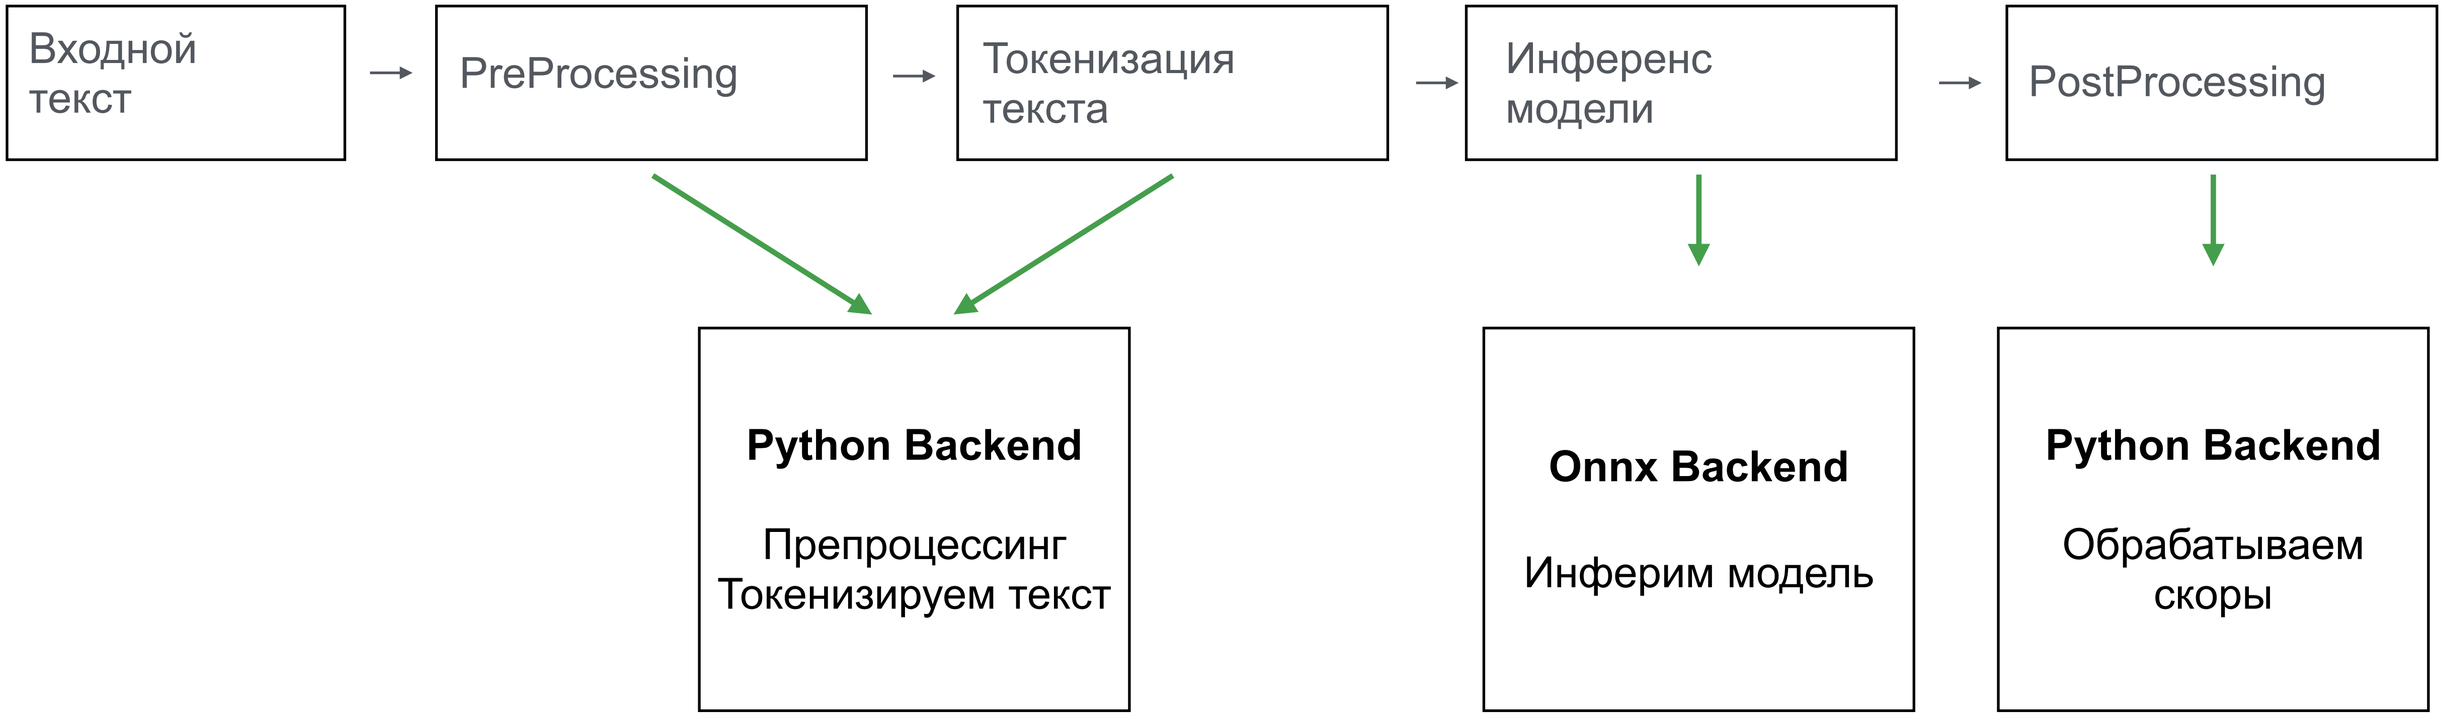

Ансамблирование пайплайна

Задача классификации текста

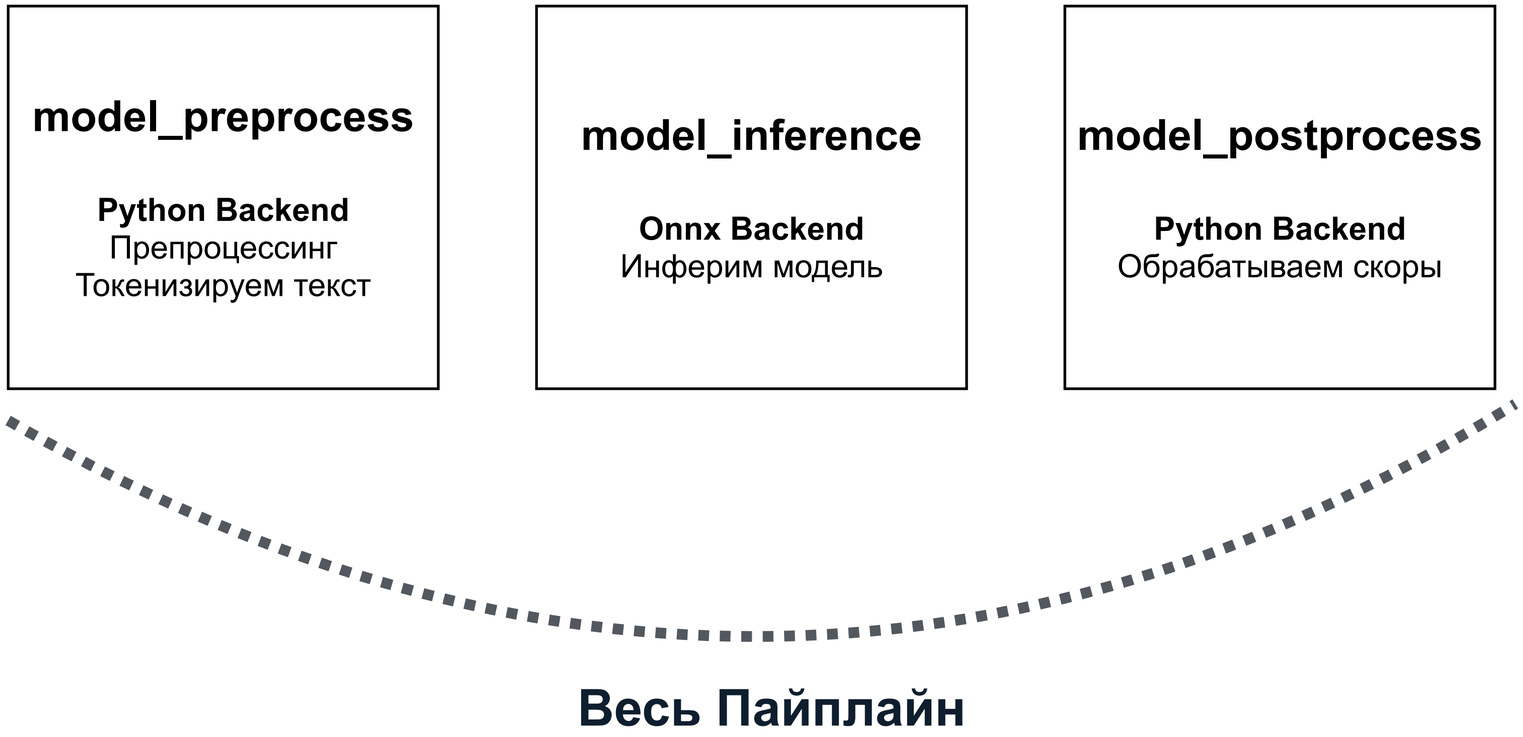

Ансамблирование пайплайна

Задача классификации текста

model_preprocess

Python Backend
Препроцессинг
Токенизируем текст

```
name: "model_preprocessing"
backend: "python"
max_batch_size: 0


input [
    {
        name: "TEXT"
        data_type: TYPE_STRING
        dims: [ -1, 1 ]
    }
]

output [
    {
        name: "input_ids"
        data_type: TYPE_INT64
        dims: [ -1, 512 ]
    },
    {
        name: "attention_mask"
        data_type: TYPE_INT64
        dims: [ -1, 512 ]
    }
]

instance_group [
    {
        count: 4
        kind: KIND_CPU
    }
]

parameters: {
    key: "EXECUTION_ENV_PATH",
    value: {string_value: "$$TRITON_MODEL_DIRECTORY/triton_env.tar.gz"}
}
```

Ансамблирование пайплайна

Задача классификации текста

model_inference

Onnx Backend
Инферим модель

```
name: "model_inference"
platform: "onnxruntime_onnx"
max_batch_size: 0

input [
    {
        name: "input_ids"
        data_type: TYPE_INT64
        dims: [ -1, 512 ]
    },
    {
        name: "attention_mask"
        data_type: TYPE_INT64
        dims: [ -1, 512 ]
    }
]

output [
    {
        name: "logits"
        data_type: TYPE_FP32
        dims: [ -1, 1 ]
    }
]

instance_group [
    {
        count: 1
        kind: KIND_GPU
    }
]
```

Ансамблирование пайплайна

Задача классификации текста

model_postprocess

Python Backend
Обрабатываем скоры

```
name: "model_postprocessing"
backend: "python"
max_batch_size: 0

input [
    {
        name: "logits"
        data_type: TYPE_FP32
        dims: [ -1, 1 ]
    },
    {
        name: "THRESHOLD"
        data_type: TYPE_FP32
        dims: [ -1 ]
    }
]

output [
    {
        name: "PROBABILITIES"
        data_type: TYPE_FP32
        dims: [ -1, -1 ]
    },
    {
        name: "VERDICTS"
        data_type: TYPE_BOOL
        dims: [ -1, -1 ]
    }
]

instance_group [
    {
        count: 4
        kind: KIND_CPU
    }
]
```

Ансамблирование пайплайна

Задача классификации текста

model_ensemble

```
name: "model_ensemble"
max_batch_size: 0
platform: "ensemble"

input [
    {
        name: "TEXT"
        data_type: TYPE_STRING
        dims: [ -1, 1 ]
    },
    {
        name: "TRUE_THRESHOLD"
        data_type: TYPE_FP32
        dims: [ -1 ]
    }
]

output [
    {
        name: "PROBABILITIES"
        data_type: TYPE_FP32
        dims: [ -1, -1 ]
    },
    {
        name: "VERDICTS"
        data_type: TYPE_BOOL
        dims: [ -1, -1 ]
    }
]
```

Ансамблирование пайплайна

Задача классификации текста

model_ensemble

```
name: "model_ensemble"
max_batch_size: 0
platform: "ensemble"

input [
    {
        name: "TEXT"
        data_type: TYPE_STRING
        dims: [ -1, 1 ]
    },
    {
        name: "TRUE_THRESHOLD"
        data_type: TYPE_FP32
        dims: [ -1 ]
    }
]

output [
    {
        name: "PROBABILITIES"
        data_type: TYPE_FP32
        dims: [ -1, -1 ]
    },
    {
        name: "VERDICTS"
        data_type: TYPE_BOOL
        dims: [ -1, -1 ]
    }
]
```

Ансамбль - спецификация, определяющая порядок передачи данных между моделями с **консистентными** входами и выходами.

Ансамблирование пайплайна

Задача классификации текста

Ансамбль - спецификация, **определяющая порядок** передачи данных между моделями с консистентными входами.

```
ensemble_scheduling {
  step [
    {
      model_name: "model_name"
      model_version: 1
      input_map [
        {
          key: "INPUT_1"
          value: "INPUT_1"
        }
      ]
      output_map [
        {
          key: "OUTPUT_1"
          value: "OUTPUT_1"
        },
        {
          key: "OUTPUT_2"
          value: "OUTPUT_2"
        }
      ]
    },
    {
      model_name: "another_model"
      ...
    },
  ]
}
```

Ансамблирование пайплайна

Задача классификации текста

Ансамбль - спецификация, определяющая порядок передачи данных между моделями с **консистентными** входами.

```
ensemble_scheduling {
  step [
    {
      model_name: "model_name"
      model_version: 1
      input_map [
        {
          key: "INPUT_1"
          value: "INPUT_1"
        }
      ]
      output_map [
        {
          key: "OUTPUT_1"
          value: "OUTPUT_1"
        },
        {
          key: "OUTPUT_2"
          value: "OUTPUT_2"
        }
      ]
    },
    {
      model_name: "another_model"
      ...
    },
  ]
}
```

Название модели

Ансамблирование пайплайна

Задача классификации текста

Ансамбль - спецификация, определяющая порядок передачи данных между моделями с **консистентными** входами.

```
ensemble_scheduling {
  step [
    {
      model_name: "model_name"
      model_version: 1
      input_map [
        {
          key: "INPUT_1"
          value: "INPUT_1"
        }
      ]
      output_map [
        {
          key: "OUTPUT_1"
          value: "OUTPUT_1"
        },
        {
          key: "OUTPUT_2"
          value: "OUTPUT_2"
        }
      ]
    },
    {
      model_name: "another_model"
      ...
    },
  ]
}
```

Название модели

Версия модели

Ансамблирование пайплайна

Задача классификации текста

Ансамбль - спецификация, определяющая порядок передачи данных между моделями с **консистентными** входами.

```
ensemble_scheduling {
  step [
    {
      model_name: "model_name"
      model_version: 1
      input_map [
        {
          key: "INPUT_1"
          value: "INPUT_1"
        }
      ]
      output_map [
        {
          key: "OUTPUT_1"
          value: "OUTPUT_1"
        },
        {
          key: "OUTPUT_2"
          value: "OUTPUT_2"
        }
      ]
    },
    {
      model_name: "another_model"
      ...
    },
  ]
}
```

Название модели

Версия модели

Сопоставление входных данных

Ансамблирование пайплайна

Задача классификации текста

Ансамбль - спецификация, определяющая порядок передачи данных между моделями с **консистентными** входами.

```
ensemble_scheduling {
  step [
    {
      model_name: "model_name"
      model_version: 1
      input_map [
        {
          key: "INPUT_1"
          value: "INPUT_1"
        }
      ]
      output_map [
        {
          key: "OUTPUT_1"
          value: "OUTPUT_1"
        },
        {
          key: "OUTPUT_2"
          value: "OUTPUT_2"
        }
      ]
    },
    {
      model_name: "another_model"
      ...
    },
  ]
}
```

Название модели

Версия модели

Сопоставление входных данных

Сопоставление выходных данных

Ансамблирование пайплайна

Задача классификации текста

Ансамбль - спецификация, определяющая порядок передачи данных между моделями с **консистентными** входами.

```
ensemble_scheduling {
  step [
    {
      model_name: "model_name"
      model_version: 1
      input_map [
        {
          key: "INPUT_1"
          value: "INPUT_1"
        }
      ]
      output_map [
        {
          key: "OUTPUT_1"
          value: "OUTPUT_1"
        },
        {
          key: "OUTPUT_2"
          value: "OUTPUT_2"
        }
      ]
    },
    {
      model_name: "another_model"
      ...
    },
  ]
}
```

Название модели

Версия модели

Сопоставление входных данных

Сопоставление выходных данных

Следующая компонента ансамбля

Частые ошибки при настройке Ensemble

Что идёт не так — и как это исправить

01

Несовпадение имён тензоров

```
✗ output_map { key: "output" value: "INPUT_IDS" }
✓ output_map { key: "INPUT_IDS" value: "INPUT_IDS" }
```

key должен совпадать с output_names модели-источника

02

model_version: 0 вместо -1

```
✗ model_version: 0   # ← ошибка
✓ model_version: -1  # ← всегда последняя версия
```

0 означает «не выбрана» → модель не найдена

03

CPU vs GPU — несовпадение инстансов

```
✗ instance_group [{ kind: KIND_CPU }]  # в подмодели
✓ instance_group [{ kind: KIND_GPU }]  # единообразно
```

Смешивание KIND_CPU и KIND_GPU в одном ансамбле → лишние копии памяти

04

dims: [-1] vs dims: [1, -1]

```
✗ dims: [ -1 ]       # 1D, но модель ждёт 2D
✓ dims: [ 1, -1 ]    # batch × sequence_len
```

Несоответствие формы тензора → STATUS_INVALID_ARGUMENT

05

Отсутствует выходной тензор ансамбля

```
✗ # output [] — пустой блок или не указан
✓ output [{ name: "VERDICTS" ... }]
```

Если output ансамбля не объявлен — Triton не знает что вернуть клиенту

Ансамблирование пайплайна

Задача классификации текста

```
name: "model_ensemble"
max_batch_size: 0
platform: "ensemble"

input [
    {
        name: "TEXT"
        data_type: TYPE_STRING
        dims: [ -1, 1 ]
    },
    {
        name: "TRUE_THRESHOLD"
        data_type: TYPE_FP32
        dims: [ -1 ]
    }
]

output [
    {
        name: "PROBABILITIES"
        data_type: TYPE_FP32
        dims: [ -1, -1 ]
    },
    {
        name: "VERDICTS"
        data_type: TYPE_BOOL
        dims: [ -1, -1 ]
    }
]
```

model_preprocess

Python Backend
Препроцессинг
Токенизируем текст

model_inference

Onnx Backend
Инферим модель

model_postprocess

Python Backend
Обрабатываем скоры

```
{
  model_name: "model_preprocessing"
  model_version: 1
  input_map [
    {
      key: "TEXT"
      value: "TEXT"
    }        ]
  output_map [
    {
      key: "input_ids"
      value: "input_ids"
    },
    {
      key: "attention_mask"
      value: "attention_mask"
    }
  ]
}
```

Ансамблирование пайплайна

Задача классификации текста

```
name: "model_ensemble"
max_batch_size: 0
platform: "ensemble"

input [
    {
        name: "TEXT"
        data_type: TYPE_STRING
        dims: [ -1, 1 ]
    },
    {
        name: "TRUE_THRESHOLD"
        data_type: TYPE_FP32
        dims: [ -1 ]
    }
]

output [
    {
        name: "PROBABILITIES"
        data_type: TYPE_FP32
        dims: [ -1, -1 ]
    },
    {
        name: "VERDICTS"
        data_type: TYPE_BOOL
        dims: [ -1, -1 ]
    }
]
```

model_preprocess

Python Backend
Препроцессинг
Токенизируем текст

model_inference

Onnx Backend
Инферим модель

model_postprocess

Python Backend
Обрабатываем скоры

```
{
    model_name: "model_preprocessing"
    model_version: 1
    input_map [
        {
            key: "TEXT"
            value: "TEXT"
        }        ]
    output_map [
        {
            key: "input_ids"
            value: "input_ids"
        },
        {
            key: "attention_mask"
            value: "attention_mask"
        }
    ]
}
```

```
{
    model_name: "model_inference"
    model_version: 1
    input_map [
        {
            key: "input_ids"
            value: "input_ids"
        },
        {
            key: "attention_mask"
            value: "attention_mask"
        }
    ]
    output_map [
        {
            key: "logits"
            value: "logits"
        }
    ]
}
```

Ансамблирование пайплайна

Задача классификации текста

```
name: "model_ensemble"
max_batch_size: 0
platform: "ensemble"

input [
    {
        name: "TEXT"
        data_type: TYPE_STRING
        dims: [ -1, 1 ]
    },
    {
        name: "TRUE_THRESHOLD"
        data_type: TYPE_FP32
        dims: [ -1 ]
    }
]

output [
    {
        name: "PROBABILITIES"
        data_type: TYPE_FP32
        dims: [ -1, -1 ]
    },
    {
        name: "VERDICTS"
        data_type: TYPE_BOOL
        dims: [ -1, -1 ]
    }
]
```

model_preprocess

Python Backend
Препроцессинг
Токенизируем текст

```
{
    model_name: "model_preprocessing"
    model_version: 1
    input_map [
        {
            key: "TEXT"
            value: "TEXT"
        }        ]
    output_map [
        {
            key: "input_ids"
            value: "input_ids"
        },
        {
            key: "attention_mask"
            value: "attention_mask"
        }
    ]
}
```

model_inference

Onnx Backend
Инферим модель

```
{
    model_name: "model_inference"
    model_version: 1
    input_map [
        {
            key: "input_ids"
            value: "input_ids"
        },
        {
            key: "attention_mask"
            value: "attention_mask"
        }
    ]
    output_map [
        {
            key: "logits"
            value: "logits"
        }
    ]
}
```

model_postprocess

Python Backend
Обрабатываем скоры

```
{
    model_name: "model_postprocessing"
    model_version: 1
    input_map [
        {
            key: "TRUE_THRESHOLD"
            value: "TRUE_THRESHOLD"
        },
        {
            key: "logits"
            value: "logits"
        }
    ]
    output_map [
        {
            key: "VERDICTS"
            value: "VERDICTS"
        },
        {
            key: "PROBABILITIES"
            value: "PROBABILITIES"
        }
    ]
}
```

Ансамблирование пайплайна

Задача классификации текста

```
name: "model_ensemble"
max_batch_size: 0
platform: "ensemble"

input [
    {
        name: "TEXT"
        data_type: TYPE_STRING
        dims: [ -1, 1 ]
    },
    {
        name: "TRUE_THRESHOLD"
        data_type: TYPE_FP32
        dims: [ -1 ]
    }
]

output [
    {
        name: "PROBABILITIES"
        data_type: TYPE_FP32
        dims: [ -1, -1 ]
    },
    {
        name: "VERDICTS"
        data_type: TYPE_BOOL
        dims: [ -1, -1 ]
    }
]
```

model_postprocess

Python Backend
Обрабатываем скоры

```
{
    model_name: "model_postprocessing"
    model_version: 1
    input_map [
        {
            key: "TRUE_THRESHOLD"
            value: "TRUE_THRESHOLD"
        },
        {
            key: "logits"
            value: "logits"
        }
    ]
    output_map [
        {
            key: "VERDICTS"
            value: "VERDICTS"
        },
        {
            key: "PROBABILITIES"
            value: "PROBABILITIES"
        }
    ]
}
```

В step’е ансамбля мы нигде не указываем тип данных и размерность, только в конфиге.
Размерность и тип выходов step’а берутся из конфига каждого шага отдельно.

Ансамблирование пайплайна

Задача классификации текста

В step’е ансамбля мы нигде не указываем тип данных и размерность, только в конфиге.
Размерность и тип выходов step’а берутся из конфига каждого шага отдельно.

```
{
  model_name: "model_postprocessing"
  model_version: 1
  input_map [
    {
      key: "TRUE_THRESHOLD"
      value: "TRUE_THRESHOLD"
    },
    {
      key: "logits"
      value: "logits"
    }
  ]
  output_map [
    {
      key: "VERDICTS"
      value: "VERDICTS"
    },
    {
      key: "PROBABILITIES"
      value: "PROBABILITIES"
    }
  ]
}
```

```
name: "model_postprocessing"
backend: "python"
max_batch_size: 0

input [
    {
        name: "logits"
        data_type: TYPE_FP32
        dims: [ -1, 1 ]
    },
    {
        name: "THRESHOLD"
        data_type: TYPE_FP32
        dims: [ -1 ]
    }
]

output [
    {
        name: "PROBABILITIES"
        data_type: TYPE_FP32
        dims: [ -1, -1 ]
    },
    {
        name: "VERDICTS"
        data_type: TYPE_BOOL
        dims: [ -1, -1 ]
    }
]

instance_group [
    {
        count: 4
        kind: KIND_CPU
    }
]
```

Ансамблирование пайплайна

Задача классификации текста

```
model_repository
├── ensemble_model
│   ├── 1
│   └── config.pbtxt
├── model
│   ├── 1
│   │   └── distilbert-base-uncased-finetuned-sst-2-english.onnx
│   └── config.pbtxt
└── tokenizer
    ├── 1
    │   ├── config.json
    │   ├── model.py
    │   ├── special_tokens_map.json
    │   ├── tokenizer.json
    │   ├── tokenizer_config.json
    │   └── vocab.txt
    └── config.pbtxt
```

Ансамблирование пайплайна

Ансамбль может включать в себя несколько моделей

Photo OCR pipeline

1. Text detection

1.

detection_preprocess	detection_inference
Python Backend	Onnx Backend

Ансамблирование пайплайна

Ансамбль может включать в себя несколько моделей

Photo OCR pipeline

1. Text detection

2. Character segmentation

1.

detection_preprocess

Python Backend

detection_inference

Onnx Backend

2.

detection_postprocess

Python Backend
- Crop Bounding Box
- Align Bounding Box

recognition_preprocess

Python Backend
Image resize + normalize

Ансамблирование пайплайна

Ансамбль может включать в себя несколько моделей

Photo OCR pipeline

1. Text detection

2. Character segmentation

3. Character classification

1.

detection_preprocess

Python Backend

detection_inference

Onnx Backend

2.

detection_postprocess

Python Backend
- Crop Bounding Box
- Align Bounding Box

recognition_preprocess

Python Backend
Image resize + normalize

3.

recognition_inference

Onnx Backend

recognition_postprocess

Onnx Backend

Ансамблирование пайплайна

Ансамбль может иметь параллельную структуру.

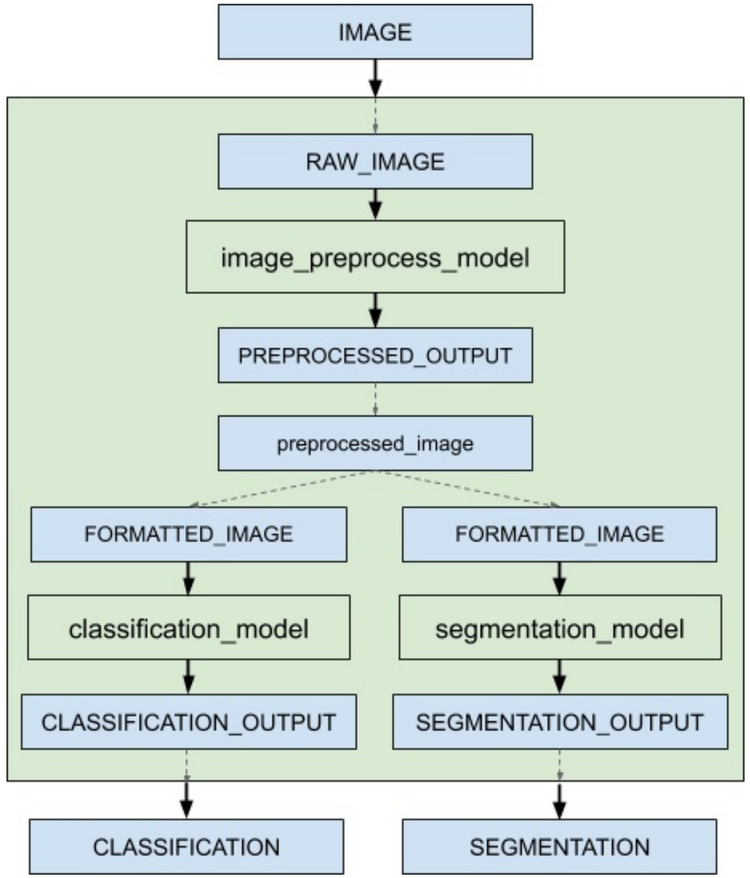

ozontech

Ансамблирование пайплайна

Ансамбль может иметь параллельную структуру.

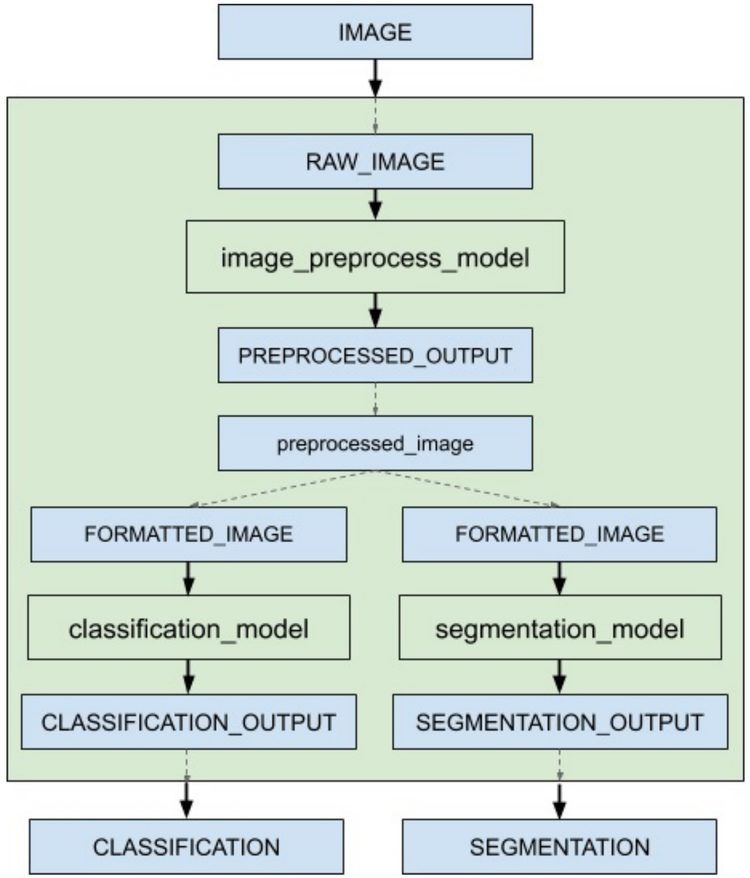

1. На вход в ансамбль приходит изображение («IMAGE» tensor), которое сопоставляется input «RAW_IMAGE».

ozontech

Ансамблирование пайплайна

Ансамбль может иметь параллельную структуру.

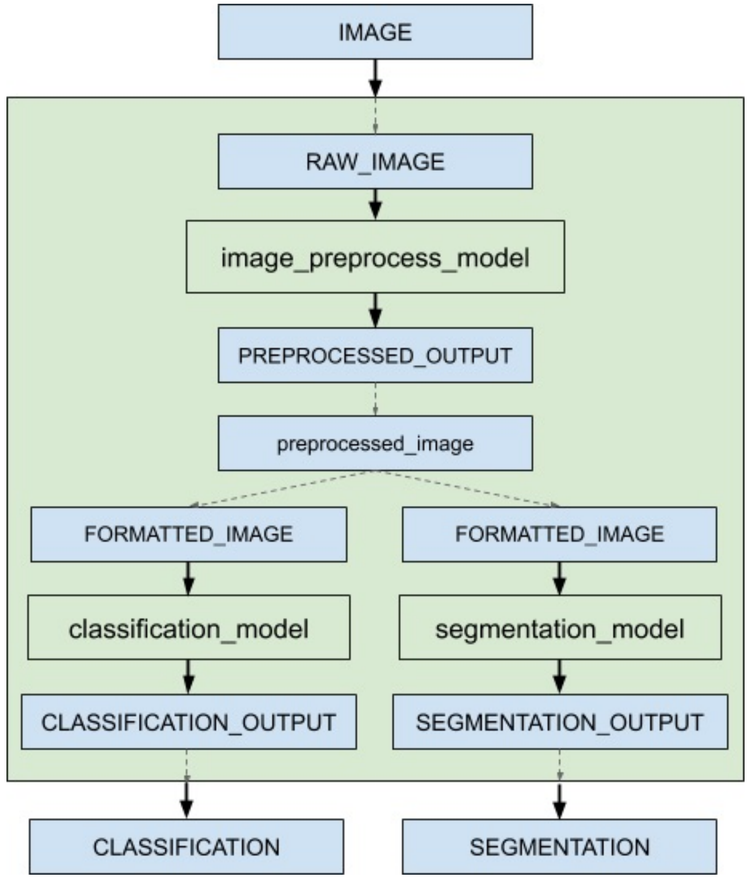

1. На вход в ансамбль приходит изображение («IMAGE» tensor), которое сопоставляется input «RAW_IMAGE».
2. Отправляется внутренний запрос в модель preprocessing.

ozontech

Ансамблирование пайплайна

Ансамбль может иметь параллельную структуру.

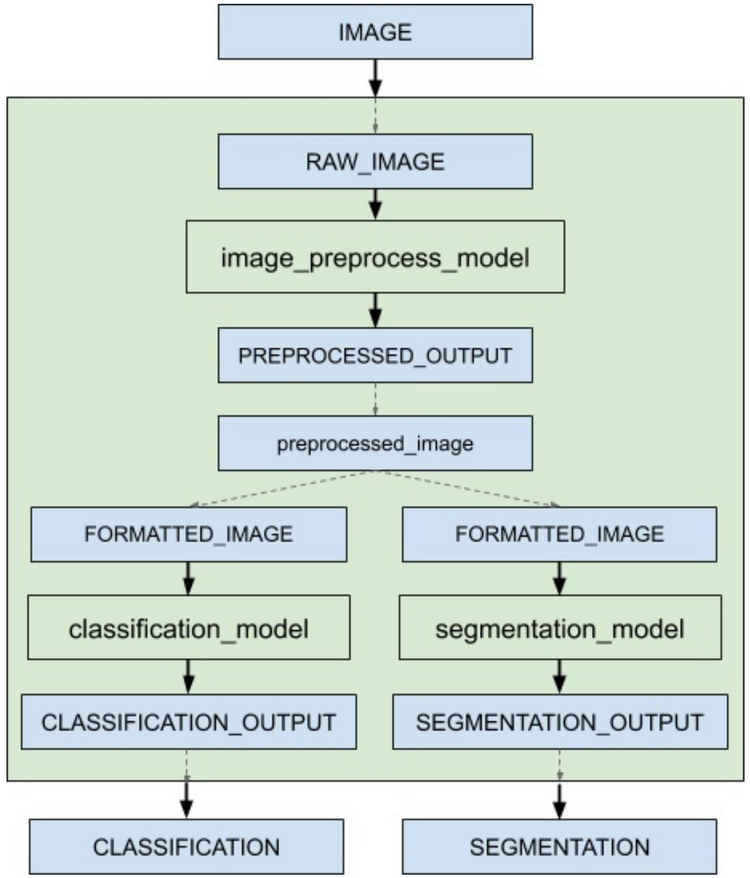

1. На вход в ансамбль приходит изображение («IMAGE» tensor), которое сопоставляется input «RAW_IMAGE».
2. Отправляется внутренний запрос в модель preprocessing.
3. Получаем предобработанное изображение «PREPROCESSED_OUTPUT» и мапим в «preprocess_image».

ozontech

Ансамблирование пайплайна

Ансамбль может иметь параллельную структуру.

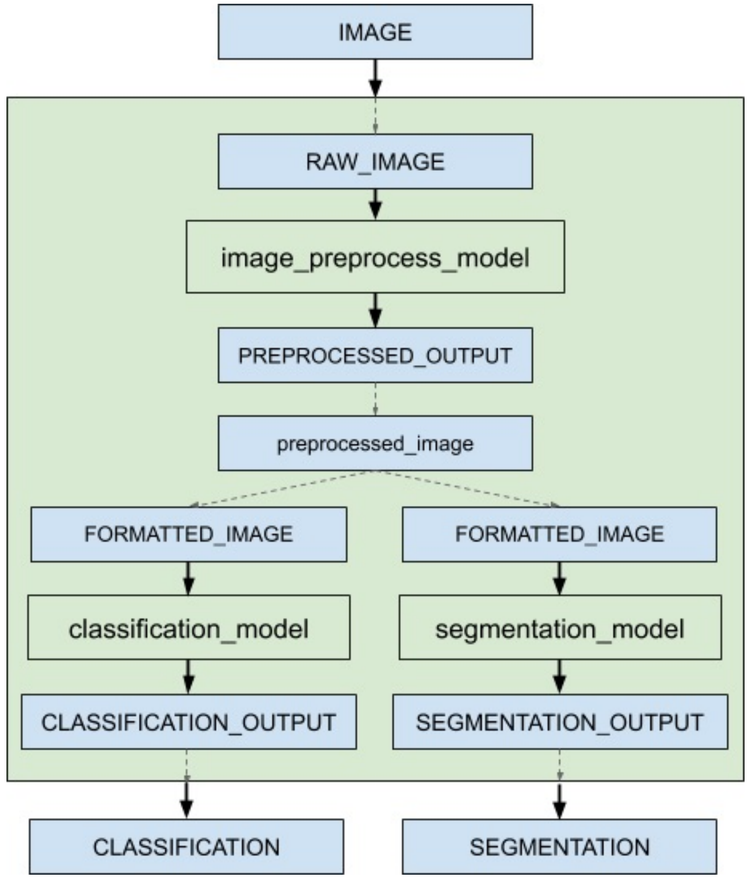

1. На вход в ансамбль приходит изображение («IMAGE» tensor), которое сопоставляется input «RAW_IMAGE».
2. Отправляется внутренний запрос в модель preprocessing.
3. Получаем предобработанное изображение «PREPROCESSED_OUTPUT» и мапим в «preprocess_image».
4. Посылаем «preprocess_image» в classification и segmentation модели.

ozontech

Ансамблирование пайплайна

Ансамбль может иметь параллельную структуру.

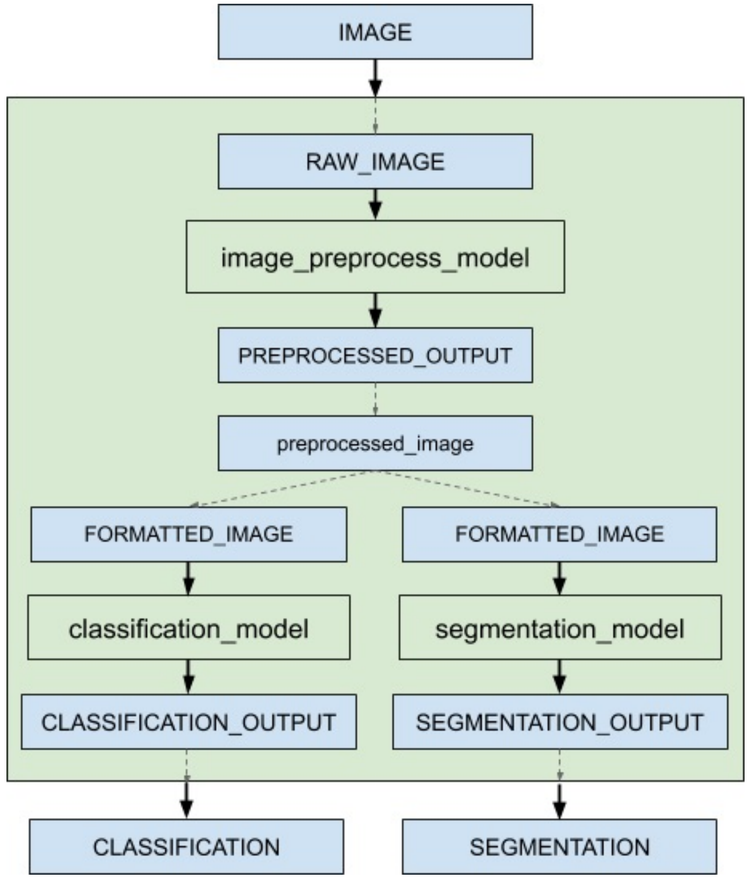

1. На вход в ансамбль приходит изображение («IMAGE» tensor), которое сопоставляется input «RAW_IMAGE».
2. Отправляется внутренний запрос в модель preprocessing.
3. Получаем предобработанное изображение «PREPROCESSED_OUTPUT» и мапим в «preprocess_image».
4. Посылаем «preprocess_image» в classification и segmentation модели.
5. Получаем результаты инференса моделей, возвращаем их.

ozontech

Ансамблирование пайплайна

Ансамбль может иметь параллельную структуру.

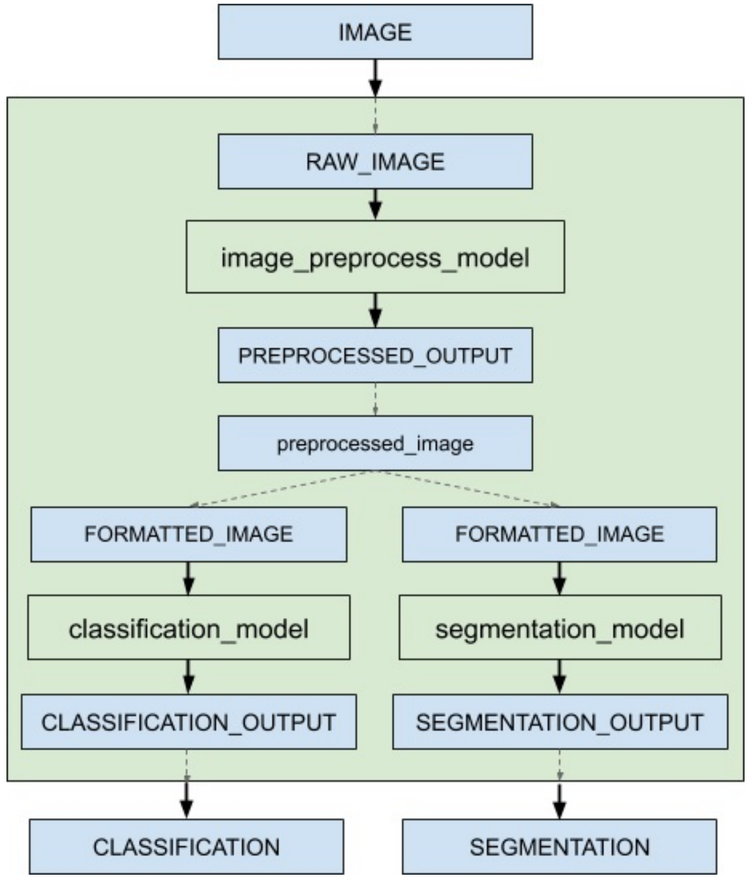


```
ensemble_scheduling {
  step [
    {
      model_name: "image_preprocess_model"
      model_version: -1
      input_map {
        key: "RAW_IMAGE"
        value: "IMAGE"
      }
      output_map {
        key: "PREPROCESSED_OUTPUT"
        value: "preprocessed_image"
      }
    },
    {
      model_name: "classification_model"
      model_version: -1
      input_map {
        key: "FORMATTED_IMAGE"
        value: "preprocessed_image"
      }
      output_map {
        key: "CLASSIFICATION_OUTPUT"
        value: "CLASSIFICATION"
      }
    },
    {
      model_name: "segmentation_model"
      model_version: -1
      input_map {
        key: "FORMATTED_IMAGE"
        value: "preprocessed_image"
      }
      output_map {
        key: "SEGMENTATION_OUTPUT"
        value: "SEGMENTATION"
      }
    }
  ]
}
```

ozontech

Ансамблирование пайплайна

Оптимизация ансамблей

В отличие от других моделей, **ансамбли не поддерживают параметр instance_group**, которым можно увеличивать число «копий» модели.

Причина в том, что сам **ансамбль в основном является событийно-управляемым планировщиком** с очень минимальными накладными расходами, поэтому он почти никогда не становится узким местом конвейера.

Составные модели в ансамбле могут быть индивидуально масштабированы по количеству с соответствующими настройками instance_group. Чтобы оптимизировать производительность ансамбля моделей, вы можете использовать **Model Analyzer** для поиска оптимальных конфигураций модели.

Ансамблирование пайплайна

А что, если?

Ансамбль - **направленный граф без циклов.** А что делать, если в пайплайне используем более сложную логику if-else?

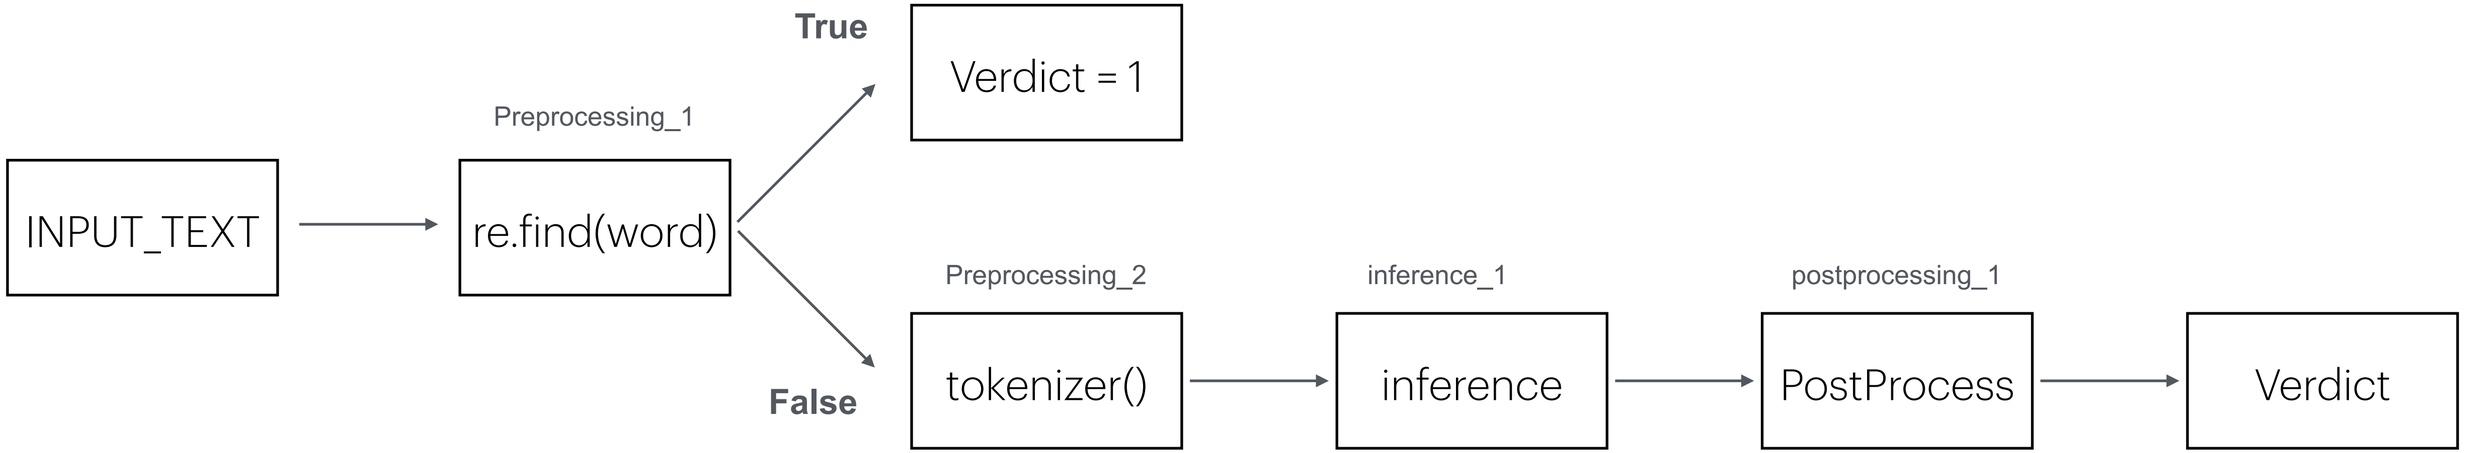

Ансамблирование пайплайна

А что, если?

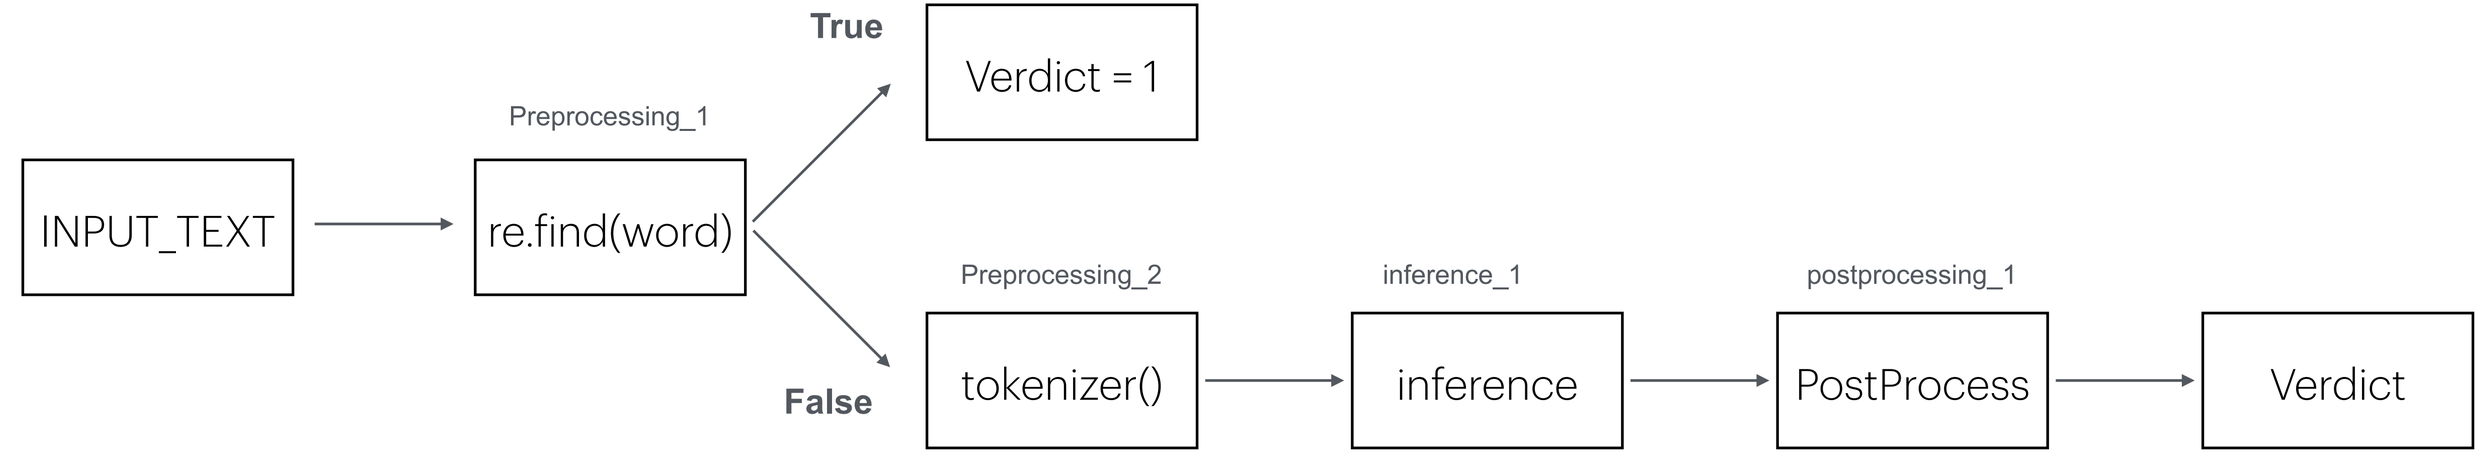

BLS backend - позволяет выполнять запросы вывода на других моделях, обслуживаемых Triton, как часть выполнения вашей модели Python

BLS следует использовать только внутри функции execute и он не поддерживается в методах initialize или finalize

Ensemble vs BLS Backend

Когда использовать каждый подход?

ENSEMBLE

- Линейный граф без ветвлений
- Предсказуемый, статичный пайплайн
- Максимальная производительность
- Низкий overhead (без Python GIL)
- config.pbtxt — простая конфигурация

BLS (Business Logic Scripting)

- Условная логика (if-else маршрутизация)
- Динамический выбор модели в runtime
- Циклы и итерации над тензорами
- Сложная бизнес-логика обработки
- Python Backend + Triton C++ API

💡 Правило выбора: Ensemble — если пайплайн известен статически. BLS — если нужен контроль потока выполнения.

Ансамблирование пайплайна

А что, если?

BLS backend - позволяет выполнять запросы вывода на других моделях, обслуживаемых Triton, как часть выполнения вашей модели Python

Из основных фичей:

1. Писать разветвленные графы.
2. Выгружать и загружать модели для разовых операций.
3. Трекать реквесты внутри тритона и снимать расширенные метрики (кроме трейсов реквестов где-то из логов контейнера тритона).
4. Можно использовать асинхронность в пайплайне.

Ссылка на документацию

Ансамблирование пайплайна

Материалы

- **Лекции от nvidia**
- **Пример nlp модели**
- **BLS**